

✓ MUSEUM ANALYSIS

```
!pip install seaborn
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid")
```

```
df=pd.read_csv("../data/museums.csv")
```

✓ 1. Introdução e Objetivos

Este projeto tem como objetivo analisar a base de dados dos museus para compreender melhor o cenário do setor cultural. A partir dessa análise, busca-se identificar padrões, tratar inconsistências nos dados e gerar informações que possam auxiliar na tomada de decisão do Nur Mah Museum.

Antes de iniciar qualquer tratamento dos dados, é importante entender como a base está estruturada. Para isso, foram utilizadas algumas funções do Pandas que permitem visualizar a quantidade de registros, os tipos das colunas e algumas estatísticas gerais do conjunto de dados.

```
df.info()
```

```
df.describe()
```

```
df.shape
```

✓ 2. Metodologia de Limpeza de Dados

✓ 2.1 Análise de Duplicatas

Como o conjunto de dados possui muitos registros, achei importante verificar se existiam duplicatas. Apesar de encontrar alguns museus com informações muito semelhantes, a análise mostrou que eles possuíam diferenças em campos

importantes, como o ID ou o endereço. Dessa forma, conclui que se tratavam de registros distintos e nenhuma linha foi removida.

```
print(df.columns.tolist())
```

```
duplicados = df[df.duplicated(
    subset=['Museum Name', 'Street Address (Physical Location)'],
    keep=False
)]

duplicados[['Museum ID', 'Museum Name', 'Street Address (Physical Location)']
```

```
duplicados = (
    df.dropna(subset=['Street Address (Physical Location)'])
    .groupby(['Museum Name', 'Street Address (Physical Location)'])
    .size()
    .reset_index(name='Quantidade')
    .query('Quantidade > 1')
    .sort_values('Quantidade', ascending=False)
)

duplicados
```

```
df = df.drop_duplicates(subset=['Museum ID'])
```

✓ 2.2 Tratamento de Dados Ausentes.

Depois dessa análise, passei para o tratamento dos dados nulos. Logo percebi que muitas colunas relacionadas a endereços possuíam valores ausentes, mesmo assim, optei por manter elas, já que esse tipo de informação não pode ser estimado de forma confiável. Além disso, como não foram encontrados registros duplicados, cada linha representa uma instituição diferente, tornando essas informações importantes para a análise, mesmo incompletas.

Já as colunas Income e Revenue foi diferente. Como são dados numéricos, seria possível utilizar médias ou outras estimativas para preencher os valores ausentes, porém como não é possível saber o motivo da ausência dessas informações, preferi transformar esses valores nulos em 0 para permitir cálculos estatísticos e criação de gráficos..

```
# Verificando a quantidade de valores nulos por coluna
print("Valores Nulos por Coluna:")
print(df.isnull().sum())

# Removendo duplicatas exatas, se existirem (como o ID não se repete, não fa
df.drop_duplicates(subset=['Museum ID']) if 'Museum ID' in df.columns else d
```

```
# Preenchendo valores nulos em colunas financeiras (ex: Income/Revenue) com
coluna_financeira = 'Income'
if coluna_financeira in df.columns:
    df[coluna_financeira] = df[coluna_financeira].fillna(0)

print(f"\nLinhas após limpeza inicial: {df.shape[0]}")
```

✓ 2.3 Tratamento de Tipos de Dados e Limpeza de Strings

Durante a análise também foi observado que algumas colunas com valores numéricos tinham caracteres especiais, espaços e letras o que acabou impedindo a leitura correta no Excel/Power BI. Por isso, foi realizada uma limpeza nesses campos antes da conversão para o formato numérico.

Abordagem: Utilizaremos o método `pd.to_numeric` com o argumento `errors='coerce'`, que transforma qualquer valor não numérico em `NaN` (Not a Number), permitindo que tratemos esses valores na sequência.

```
# Lista das colunas que apresentam erros de formatação
colunas_para_limpar = ['Phone Number', 'Zip Code (Administrative Location)',

for col in colunas_para_limpar:
    if df[col].dtype == 'object':
        df[col] = df[col].astype(str).str.replace(r'^\d.', '', regex=True)

    df[col] = pd.to_numeric(df[col], errors='coerce')

    df[col] = df[col].fillna(0)

print(df[colunas_para_limpar].dtypes)
print(df[colunas_para_limpar].head())
```

✓ 3. Análise Exploratória (EDA)

✓ 3.1 Panorama financeiro

Antes de comparar os museus entre si, é importante compreender como os valores financeiros estão distribuídos na base de dados. Para isso, foram analisadas algumas estatísticas descritivas da coluna **Income**, como média, mediana, valor mínimo e valor máximo.

```
df['Income'].describe()
```

É possível identificar que existe uma diferença muito grande entre a mediana e o valor máximo do Income, o que reforça uma distribuição bem desigual entre as instituições.

✓ 3.2 Como os recursos estão distribuídos entre os tipos de museus?

- O objetivo é descobrir quais categorias movimentam mais dinheiro.

```
# Agrupamento correto
receita_por_tipo = df.groupby('Museum Type')['Income'].sum().sort_values(asc

plt.figure(figsize=(12, 6))
sns.barplot(data=receita_por_tipo, x='Income', y='Museum Type', palette="vir
plt.title('Receita Total por Tipo de Museu', fontsize=14, fontweight='bold')
plt.show()
```

Os resultados mostram que a receita não está distribuída igualmente entre todos os tipos de museus. Algumas categorias concentram valores muito superiores às demais, indicando diferenças significativas na capacidade financeira dessas instituições

✓ 3.3 Como os museus estão distribuídos geograficamente?

Além da análise financeira, também é interessante observar como os museus estão distribuídos entre os estados. Essa visualização permite identificar regiões com maior concentração de instituições e verificar se existe predominância de determinados tipos de museus.

```
# Usando a coluna de estado administrativo que você tem
top_10_estados = df['State (Administrative Location)'].value_counts().head(1

plt.figure(figsize=(14, 7))
sns.countplot(data=df[df['State (Administrative Location)'].isin(top_10_esta
                  x='State (Administrative Location)', hue='Museum Type')
plt.title('Distribuição de Tipos de Museus nos Top 10 Estados', fontsize=14,
plt.xticks(rotation=45)
plt.show()
```

Observa-se que alguns estados apresentam uma concentração significativamente maior de museus do que outros. Além disso, a variedade de tipos também muda entre os estados, mostrando que o cenário cultural não é homogêneo.

✓ 3.4 Existem instituições que fogem completamente do padrão?

Como observado nas análises anteriores, existe uma grande diferença entre as receitas das instituições. Para verificar esse comportamento de forma mais clara, foi construído um boxplot, permitindo identificar possíveis valores extremos (outliers).

```
plt.figure(figsize=(10, 5))
sns.boxplot(data=df, x='Income', color="coral")
plt.title('Boxplot da Receita', fontsize=14, fontweight='bold')
plt.xlabel('Receita (Income)', fontsize=12)
plt.ticklabel_format(style='plain', axis='x')
plt.show()
museu_mais_rico = df.loc[df['Income'].idxmax()]
print(f"O museu com maior receita é do tipo {museu_mais_rico['Museum Type']}")
```

O boxplot mostra que existem instituições com receitas muito acima da maioria. Isso indica uma forte concentração financeira, sugerindo que poucas organizações possuem um peso muito maior dentro do setor.

5. Conclusões e Considerações Finais

Ao longo deste projeto foi possível conhecer melhor a base de dados dos museus, identificar inconsistências e realizar os tratamentos necessários para tornar os dados mais confiáveis. A análise mostrou que existem diferenças significativas entre os tipos de museus em relação à receita, além de uma distribuição geográfica bastante variada entre os estados. Também foi possível observar a presença de valores extremos, indicando que poucas instituições concentram grande parte dos recursos financeiros. Com a base tratada e organizada, os dados ficam prontos para serem utilizados em futuras análises e na construção de dashboards, facilitando a visualização das informações e auxiliando na tomada de decisão.

6. Metodologia de Desenvolvimento e Uso de IA

Durante o desenvolvimento deste projeto foram utilizadas ferramentas de Inteligência Artificial, como ChatGPT e Gemini, para auxiliar na compreensão da sintaxe do Jupyter Notebook, esclarecer dúvidas sobre funções da biblioteca Pandas e apoiar a organização do relatório.